

Coimbra Business School

Politécnico de Coimbra

Mestrado em Análise de Dados e Sistemas de Apoio à Decisão

Projeto de Big Data

USA Housing Listings

Docente: Ricardo Malheiro

Ano Letivo 2025-2026

Grupo:

Gonçalo Filipe Carvalho Conceição

Joana Francisca Brandão Tomé

Março de 2026

Contents

1. Descrição do Problema	3
2. Descrição do Dataset	3
2.1 Informação Geral	3
2.2 Variáveis Principais	3
3. Resumo das Operações Realizadas	4
3.1 Carregamento no Spark	4
3.2 Análise Exploratória	4
3.3 Tratamento de Valores Ausentes	5
3.4 Remoção de Colunas Irrelevantes	6
3.5 Tratamento de Outliers	6
3.6 Codificação de Variáveis Categóricas	6
3.7 Normalização de Variáveis Numéricas	7
3.8 Visualizações Produzidas	7
4. Preparação Final do Dataset para ML	10
5. Metodologia	11
5.1 Divisão Treino e Teste	11
5.2 Métricas de Avaliação	11
5.3 Modelos Implementados	11
6. Resultados	12
6.1 Comparação dos Modelos	12
6.2 Resultados do Cross-Validation	13
6.3 Importância das Features	14
7. Análise Crítica	15
7.1 Desempenho Geral dos Modelos	15
7.2 Comparação entre Modelos	15
7.3 Limitações do Dataset	15
7.4 Escolhas Técnicas	16
8. Conclusões	16
9. Avaliação 360 Graus	17

1. Descrição do Problema

O objetivo deste projeto é construir um modelo de **regressão** capaz de prever o **preço mensal de arrendamento** de imóveis nos Estados Unidos da América, com base nas suas características físicas, geográficas e de serviços disponíveis.

A previsão de preços de arrendamento é um problema relevante tanto para potenciais inquilinos que pretendem avaliar se um imóvel está corretamente avaliado como para proprietários e plataformas imobiliárias que necessitam de estimativas automáticas para novas listagens. A natureza da variável alvo (valor contínuo em USD/mês) torna este um problema de **regressão supervisionada**.

2. Descrição do Dataset

O dataset utilizado é o **USA Housing Listings (Craigslist)**, disponível publicamente no Kaggle. Trata-se de uma recolha de anúncios de arrendamento publicados na plataforma Craigslist em todo o território dos EUA, contendo informação sobre o tipo de imóvel, localização, características físicas e opções de serviços disponíveis.

2.1 Informação Geral

Atributo	Valor
Fonte	Kaggle austinreese/usa-housing-listings
Ficheiro	housing.csv
Registos	384.977
Número de colunas (original)	22
Variável alvo	price (USD/mês)
Tipo de problema	Regressão

2.2 Variáveis Principais

Coluna	Tipo	Descrição
price	Numérico	Preço mensal de arrendamento (USD) variável alvo
sqfeet	Numérico	Área do imóvel em pés quadrados
beds	Numérico	Número de quartos
baths	Numérico	Número de casas de banho
lat / long	Numérico	Coordenadas geográficas (latitude / longitude)
type	Categórico	Tipo de imóvel (apartment, house, condo, etc.)
state	Categórico	Estado dos EUA onde o imóvel está localizado
laundry_options	Categórico	Opções de lavandaria disponíveis
parking_options	Categórico	Opções de estacionamento disponíveis
cats/dogs_allowed	Binário	Permissão de animais de estimação
smoking / wheelchair	Binário	Outros atributos do imóvel
id / url / region_url / image_url	Identificador	Removidos (sem valor preditivo)
description	Texto livre	Removido (processamento NLP fora de âmbito)

3. Resumo das Operações Realizadas

3.1 Carregamento no Spark

O dataset foi inicialmente carregado para um **Spark DataFrame** utilizando `inferSchema=False`, o que significa que o Spark não inferiu automaticamente os tipos de dados das colunas, carregando todos os valores como **strings**. Esta opção foi utilizada para evitar possíveis erros de inferência de tipos, uma vez que ficheiros CSV de grande dimensão podem conter valores inconsistentes, campos vazios ou caracteres inesperados que podem levar o Spark a atribuir tipos incorretos.

Posteriormente, foram convertidas para tipo **DOUBLE** as colunas que representam valores numéricos relevantes para análise: `price`, `sqfeet`, `beds`, `baths`, `lat` e `long`. Para realizar esta conversão foi utilizada a função **TRY_CAST** do Spark SQL, aplicada através da função `expr()` do PySpark.

A utilização de `TRY_CAST` permite converter os valores válidos para o tipo numérico pretendido e, caso existam valores inválidos ou mal formatados, estes são automaticamente convertidos para **NULL** em vez de gerar uma exceção. Desta forma, garante-se que o processo de transformação de dados não é interrompido e que o DataFrame fica preparado para análises posteriores.

Por fim, foi utilizado o método `printSchema()` para confirmar que as colunas foram corretamente convertidas para o tipo **DOUBLE**, assegurando que os dados se encontram no formato adequado para operações numéricas e análises estatísticas.

3.2 Análise Exploratória

Foi realizada uma **análise exploratória dos dados (Exploratory Data Analysis – EDA)** com o objetivo de compreender a estrutura do dataset, avaliar a qualidade dos dados e identificar padrões iniciais relevantes para análises posteriores. Para esse efeito, foram executadas várias operações utilizando PySpark.

Em primeiro lugar, procedeu-se à **inspeção do esquema do DataFrame** através da função `printSchema()`, permitindo verificar os tipos de dados de cada variável. Posteriormente, foi utilizada a função `show()` para visualizar as primeiras linhas do dataset e confirmar a correta leitura dos registos.

De seguida, foram calculadas **estatísticas descritivas das principais variáveis numéricas** (`price`, `sqfeet`, `beds`, `baths`, `lat` e `long`), incluindo média, desvio-padrão, valores mínimos e máximos. Adicionalmente, foram calculados os **percentis da variável price**, nomeadamente o primeiro quartil (Q1), a mediana, o terceiro quartil (Q3) e o percentil 95 (P95), permitindo analisar a distribuição dos preços das listagens.

Os resultados indicam que o dataset contém **384.977 registos e 22 variáveis**, correspondentes a anúncios de habitação em diferentes regiões dos Estados Unidos. A análise da variável `price` revela uma **distribuição fortemente assimétrica à direita**, evidenciada pela diferença significativa entre a média (**8.825 USD**) e a mediana (**1.037 USD**). Os quartis mostram que cerca de metade das listagens apresenta preços entre **806 USD e 1.395 USD**, enquanto o percentil 95 se situa nos **2.258 USD**. O valor máximo extremamente elevado sugere a existência de **outliers ou possíveis inconsistências nos dados**.

Relativamente às características dos imóveis, a área média (sqfeet) é de aproximadamente **1.060 pés quadrados**, embora com elevada variabilidade. Em média, os imóveis possuem cerca de **1,9 quartos** e **1,48 casas de banho**, indicando que grande parte das listagens corresponde a habitações de pequena ou média dimensão.

Foi também realizada uma **análise de valores em falta**, através do cálculo da contagem e da percentagem de valores nulos em cada coluna. Observou-se que a maioria das variáveis apresenta dados completos. Contudo, algumas colunas apresentam percentagens relevantes de valores em falta, nomeadamente parking_options (cerca de **36,5%**) e laundry_options (aproximadamente **20,5%**). As variáveis geográficas (lat e long) apresentam apenas cerca de **0,5% de valores nulos**, o que representa uma proporção reduzida.

Adicionalmente, foi analisada a **distribuição das listagens por tipo de imóvel**. Verificou-se que a categoria dominante é **apartment**, com mais de **318 mil registos**, representando a grande maioria das observações do dataset. Outras categorias presentes incluem house, townhouse, condo e duplex, mas com frequências consideravelmente inferiores.

Por fim, analisou-se a **distribuição geográfica das listagens por estado**, observando-se que os estados com maior número de anúncios são **Califórnia (ca)**, **Florida (fl)** e **Texas (tx)**, seguidos por estados como **Carolina do Norte**, **Michigan** e **Geórgia**. Estes resultados sugerem uma maior concentração de dados em estados mais populosos ou com maior dinamismo no mercado de arrendamento.

De forma geral, esta análise exploratória permitiu **compreender a estrutura do dataset, identificar potenciais problemas de qualidade dos dados e obter uma visão inicial das características do mercado de habitação representado nos dados**, constituindo uma etapa fundamental para as fases seguintes de análise e modelação.

3.3 Tratamento de Valores Ausentes

Após a análise exploratória, foi realizado um processo de **limpeza e tratamento de valores em falta (data cleaning)** com o objetivo de melhorar a qualidade do dataset e prepará-lo para análises posteriores.

Numa primeira etapa, procedeu-se à verificação da variável **price**, considerada a variável principal do dataset. A coluna foi novamente convertida para o tipo **DOUBLE**, garantindo que quaisquer valores inválidos ou em formato textual seriam convertidos para NULL. De seguida, foram removidos os registos com valores nulos nesta variável através da função dropna(). No entanto, verificou-se que **não existiam registos com preço nulo**, mantendo-se o total de **384.977 observações**.

Posteriormente, foi realizada uma verificação dos valores nulos em algumas das colunas mais relevantes do dataset, incluindo variáveis numéricas, categóricas e geográficas. Esta análise revelou que as colunas sqfeet, beds, baths, type e state não apresentavam valores em falta, enquanto as coordenadas geográficas (lat e long) possuíam **1.918 valores nulos**. Além disso, as variáveis categóricas laundry_options e parking_options apresentavam um número significativo de valores em falta.

De seguida, procedeu-se ao **preenchimento dos valores nulos nas variáveis categóricas** (type, laundry_options, parking_options e state) através da substituição pelo valor "unknown". Esta abordagem permite preservar os registos no dataset sem perder informação potencialmente útil, mantendo simultaneamente a distinção entre valores conhecidos e desconhecidos.

Para as variáveis numéricas, foi aplicada uma estratégia de imputação baseada em medidas estatísticas da distribuição. No caso da variável **sqfeet**, os valores nulos foram substituídos pela **mediana da distribuição (949)**, uma vez que esta medida é menos sensível à presença de valores extremos. Já nas variáveis **beds** e **baths**, os valores nulos foram preenchidos com a **moda**, correspondendo aos valores mais frequentes observados no dataset, que foram **2 quartos** e **1 casa de banho**, respetivamente.

Relativamente às variáveis geográficas **lat** e **long**, optou-se por remover os registos que continham valores em falta, uma vez que estas coordenadas são importantes para análises espaciais e geográficas. Este processo resultou na remoção de **1.918 registos**, correspondendo a aproximadamente **0,5% do dataset**, permanecendo **383.059 registos válidos**.

Por fim, foi realizada uma verificação final para confirmar a existência de valores nulos nas principais variáveis analisadas. Os resultados demonstraram que **não permanecem valores nulos nas colunas consideradas**, indicando que o dataset se encontra devidamente limpo e preparado para as etapas seguintes de análise ou modelação.

3.4 Remoção de Colunas Irrelevantes

Após a limpeza dos dados, foram removidas as colunas **id**, **url**, **region_url**, **image_url** e **description**. Estas variáveis correspondem principalmente a **identificadores ou campos de texto livre**, que não fornecem informação relevante para a análise ou para a construção de modelos preditivos.

A remoção destas colunas permite **reduzir a dimensionalidade do dataset** e manter apenas as variáveis potencialmente úteis para a análise, como características do imóvel e informações de localização.

Após esta etapa, o dataset passou a conter **17 colunas** consideradas relevantes para as fases seguintes do trabalho.

3.5 Tratamento de Outliers

Para remover valores claramente irreais ou outliers, foram aplicados filtros às principais variáveis numéricas, mantendo apenas registos dentro de intervalos plausíveis para imóveis residenciais nos EUA. A tabela seguinte resume os limites utilizados e a justificação de cada critério.

Coluna	Mínimo	Máximo	Justificação
price	100 USD	10.000 USD	Faixa típica de arrendamentos residenciais nos EUA
sqfeet	50 sq ft	10.000 sq ft	Abaixo de 50 sq ft não é habitável; acima de 10.000 sq ft é residência de luxo extremo
beds	0	10	Imóveis com mais de 10 quartos são excecionais
baths	0	10	Critério análogo ao número de quartos

3.6 Codificação de Variáveis Categóricas

As variáveis categóricas **type**, **laundry_options**, **parking_options** e **state** foram transformadas através de um **pipeline de codificação de duas etapas**, com o objetivo de preparar os

dados para utilização em modelos de machine learning que exigem entradas numéricas. A abordagem utilizada combinou **StringIndexer** e **OneHotEncoder**, cada uma com funções complementares:

1. **StringIndexer**: converte cada categoria em um **índice numérico**, atribuindo valores inteiros a cada categoria com base na frequência decrescente. Por exemplo, a categoria mais frequente recebe o índice 0. Esta etapa permite transformar variáveis categóricas em números, mas introduz uma **ordem artificial**, que não representa qualquer relação quantitativa entre as categorias.
2. **OneHotEncoder**: transforma os índices num **vetor binário esparsa**, onde cada posição representa uma categoria diferente. Esta representação elimina a ordem artificial introduzida pelo StringIndexer, garantindo que o modelo **não interprete as categorias como grandezas ordinais**, o que poderia distorcer os resultados.

O parâmetro `handleInvalid='keep'` foi utilizado nos indexadores para garantir que **categorias não vistas durante o treino** não causem erros na fase de inferência, permitindo que o pipeline seja mais robusto a novos dados.

Esta abordagem de codificação é essencial para modelos de regressão ou algoritmos baseados em vetores, pois **transforma informações categóricas em formato numérico adequado**, preservando a informação contida nas variáveis sem introduzir enviesamento devido à ordem das categorias.

3.7 Normalização de Variáveis Numéricas

As variáveis numéricas `sqfeet`, `beds`, `baths`, `lat` e `long` foram **padronizadas** para colocar todas na mesma escala, evitando que variáveis com valores maiores (como área ou coordenadas) dominem os modelos. Primeiro, o **VectorAssembler** juntou estas colunas num único vetor (`features_num_raw`), conforme exigido pelos algoritmos do Spark MLlib.

Depois, aplicou-se o **StandardScaler** com `withMean=True` e `withStd=True`, transformando cada valor para que a média fosse 0 e o desvio-padrão 1. Desta forma, os dados mantêm a distribuição original, mas ficam **normalizados**, prontos para serem usados em modelos de machine learning sem que a diferença de escalas prejudique os resultados.

3.8 Visualizações Produzidas

Análise dos Gráficos




Gráfico 1 - Distribuição do Preço de Arrendamento

O histograma revela uma distribuição do preço fortemente assimétrica à direita (right-skewed), com a grande maioria dos imóveis a concentrar-se na faixa entre os 500 e os 1.500 USD/mês. A curva KDE confirma esta tendência, com um pico bem definido na região de menor preço e uma cauda longa que se estende até valores próximos dos 10.000 USD/mês. O box-plot complementa esta análise ao mostrar que a mediana se situa abaixo dos 1.200 USD/mês e que existem numerosos outliers acima do limite superior, correspondentes a imóveis de gama alta ou de grandes dimensões. Esta assimetria é relevante para a modelação, pois pode justificar a aplicação de uma transformação logarítmica à variável alvo antes do treino dos modelos de regressão.




Gráfico 2 - Área (sqfeet) vs Preço de Arrendamento

O scatter plot entre a área útil e o preço revela que a relação entre estas duas variáveis é mais fraca do que seria expectável. A nuvem de pontos encontra-se densamente concentrada na zona de menor área (abaixo dos 2.500 sqfeet) e de menor preço (abaixo dos 2.000 USD/mês), sem uma tendência linear claramente pronunciada. Esta baixa correlação visual é consistente com o valor obtido na matriz de correlação, e pode explicar-se pelo facto de a localização geográfica e o tipo de imóvel exercerem uma influência muito mais determinante sobre o preço do que a área por si só. A presença de imóveis de grande área com preços relativamente baixos reforça esta hipótese, sugerindo que imóveis rurais ou em estados menos valorizados tendem a ter áreas maiores a preços mais acessíveis.




Gráfico 3 - Preço Médio por Tipo de Imóvel

O gráfico de barras evidencia diferenças significativas no preço médio consoante o tipo de imóvel. As casas (house) e os condomínios (condo) apresentam os preços médios mais elevados, seguidos pelos townhouses e lofts, o que é consistente com a maior dimensão e tipologia de mercado destes imóveis. No extremo oposto, os tipos land, manufactured e assisted living registam os preços médios mais baixos, refletindo a sua natureza distinta e o mercado-alvo diferente. Esta variável demonstra ter um elevado poder discriminativo relativamente ao preço, pelo que a sua inclusão no modelo, através da codificação OneHotEncoder, é claramente justificada. A categoria unknown, resultante do preenchimento de valores ausentes, apresenta um valor médio intermédio, não introduzindo distorções significativas na distribuição.




Gráfico 4 - Matriz de Correlação entre Variáveis Numéricas

A matriz de correlação de Pearson entre as variáveis numéricas (price, sqfeet, beds e baths) revela correlações lineares genericamente fracas. O par beds–baths apresenta a correlação mais elevada entre preditores (cerca de 0,01), o que indica ausência de multicolinearidade relevante e que cada variável traz informação independente ao modelo. A correlação entre sqfeet e price, bem como entre beds/baths e price, é próxima de zero, confirmando que a relação entre a área ou o número de divisões e o preço não é estritamente linear no conjunto de dados em análise. Este resultado realça a importância de incluir variáveis categóricas (tipo

de imóvel, estado) e eventualmente termos de interação ou modelos não-lineares para capturar a complexidade do mercado de arrendamento. A ausência de multicolinearidade entre os preditores numéricos é um aspeto positivo, uma vez que facilita a interpretação dos coeficientes em modelos de regressão linear.




Gráfico 5 - Top 10 Estados com Mais Listagens

O gráfico de barras evidencia uma forte concentração geográfica das listagens nos estados da Califórnia (ca) e do Texas (tx), seguidos pela Flórida (fl) e Nova Iorque (ny). Esta distribuição não é surpreendente, dado que estes estados correspondem aos maiores mercados imobiliários dos Estados Unidos, com populações e economias de maior dimensão. A representatividade destes estados no dataset é relevante porque o modelo de machine learning a desenvolver na Fase 3 será fortemente influenciado pelos padrões de preço destes mercados. A variável state foi por isso incluída como preditor através de OneHotEncoder, permitindo ao modelo capturar diferenças regionais de preço de forma explícita. Estados com menor número de listagens, como Virginia (va) ou Michigan (mi), poderão ter estimativas menos precisas devido à menor quantidade de dados disponíveis para treino.

Foram gerados 5 gráficos para apoiar a análise exploratória:

Gráfico	Tipo	Objetivo
Distribuição do Preço	Histograma + KDE + Boxplot	Visualizar a distribuição e assimetria da variável alvo
Área vs Preço	Scatter plot	Avaliar a relação entre a área do imóvel e o preço
Preço Médio por Tipo	Barras	Comparar o preço médio entre os diferentes tipos de imóvel
Matriz de Correlação	Heatmap	Identificar correlações lineares entre variáveis numéricas
Top 10 Estados	Barras	Perceber a distribuição geográfica das listagens

4. Preparação Final do Dataset para ML

No final da pipeline, os vetores numéricos padronizados e os vetores OHE das variáveis categóricas foram combinados num único vetor **features** através de um segundo

VectorAssembler. A variável alvo foi renomeada para **label**, seguindo a convenção do Spark MLlib. O dataset final foi guardado em formato **Parquet** (housing_ml_ready.parquet), que oferece compressão eficiente e leitura colunar rápida, facilitando o carregamento na Fase 3.

Métrica	Valor
Registos finais	379,638
Features numéricas (StandardScaler)	sqfeet, beds, baths, lat, long
Features categóricas (OHE)	type, laundry_options, parking_options, state
Variável alvo	price (label)
Formato de saída	Parquet (housing_ml_ready.parquet)

5. Metodologia

5.1 Divisão Treino e Teste

Os dados foram divididos em dois conjuntos de forma aleatória, com uma proporção de 80% para treino e 20% para teste, usando `seed=42` para garantir a reprodutibilidade dos resultados. Esta divisão resultou em 303.633 registos de treino e 76.005 registos de teste.

A opção por uma divisão 80/20 justifica-se pela dimensão do dataset: com quase 380 mil registos, o conjunto de teste mantém um número suficientemente grande de observações (76 mil) para garantir uma avaliação estatisticamente robusta, enquanto o conjunto de treino beneficia da maior quantidade de dados possível.

5.2 Métricas de Avaliação

Para avaliar o desempenho dos modelos de regressão foram utilizadas as seguintes métricas:

- **RMSE (Root Mean Squared Error)**: penaliza fortemente erros grandes, expresso em USD. Útil para identificar modelos com previsões muito afastadas da realidade.
- **MAE (Mean Absolute Error)**: erro médio absoluto, mais robusto a outliers que o RMSE. Indica, em média, de quantos dólares o modelo erra.
- **R² (Coeficiente de Determinação)**: proporção da variância da variável alvo explicada pelo modelo. Um valor de 1,0 seria perfeito; valores próximos de 0 indicam fraco poder explicativo.
- **MAPE (Mean Absolute Percentage Error)**: exprime o erro em percentagem relativamente ao valor real, sendo independente da escala do problema.

A utilização de quatro métricas distintas permite uma avaliação mais completa e robusta, evitando conclusões enviesadas que resultariam de depender de uma única métrica.

5.3 Modelos Implementados

Foram implementados e avaliados três modelos de regressão da biblioteca Spark MLlib, tendo sido o melhor deles submetido a otimização de hiperparâmetros por Cross-Validation com Grid Search.

Modelo 1: Regressão Linear

A Regressão Linear foi utilizada como modelo de referência (baseline). Assume uma relação linear entre as features e o preço, sendo o modelo mais simples e interpretável. Foi configurada com regularização L2 (Ridge) através do parâmetro `regParam=0.1` para evitar overfitting, com um máximo de 100 iterações.

Modelo 2: Random Forest

O Random Forest é um método de ensemble que treina múltiplas árvores de decisão em paralelo (bagging) e agrega as suas previsões. É mais robusto que uma única árvore e capaz de capturar relações não-lineares. Foi configurado com 20 árvores e profundidade máxima de 5.

Modelo 3: Gradient Boosted Trees (GBT)

O GBT é um método de ensemble sequencial em que cada árvore é treinada para corrigir os erros da anterior (boosting). Tipicamente obtém melhor desempenho que o Random Forest em dados tabulares estruturados. Foi configurado com 20 iterações, profundidade máxima de 4 e learning rate de 0,1.

Otimização: GBT com Cross-Validation e Grid Search

O modelo GBT foi ainda submetido a otimização de hiperparâmetros com Cross-Validation de 3 folds e um grid de 4 combinações (`maxDepth` em {3,5} e `maxIter` em {10,20}), totalizando 12 modelos treinados. O objetivo foi verificar se era possível melhorar o desempenho do GBT de forma sistemática e sem risco de overfitting.

6. Resultados

6.1 Comparação dos Modelos

A tabela seguinte apresenta as métricas de desempenho dos quatro modelos no conjunto de teste:

Modelo	RMSE (USD)	MAE (USD)	R ²	MAPE (%)
Regressão Linear	416,75	256,23	0,4959	23,40%
Random Forest	433,09	282,16	0,4556	27,01%
GBT	398,01	253,31	0,5402	23,46%
GBT + CV	384,80	243,27	0,5702	22,43%




Gráfico 6 – Comparação dos modelos

O gráfico de barras compara as três métricas principais (RMSE, MAE e R²) entre os quatro modelos avaliados. É imediatamente visível que o GBT com Cross-Validation obteve os

melhores resultados nas três dimensões, com o RMSE mais baixo (384,80 USD) e o R^2 mais elevado (0,57). O Random Forest destaca-se negativamente, apresentando o pior desempenho apesar de ser um modelo ensemble mais complexo que a Regressão Linear, o que se explica pelos hiperparâmetros conservadores utilizados (apenas 20 árvores). Este gráfico é útil para justificar a escolha do GBT+CV como modelo final.




Gráfico 7 – Valores Reais vs Previstos

Os scatter plots mostram, para cada modelo, o preço real no eixo X e o preço previsto no eixo Y. A linha vermelha diagonal representa a previsão perfeita (previsto = real). Quanto mais os pontos se concentrarem junto a essa linha, melhor o modelo. Nos quatro painéis observa-se uma nuvem de pontos dispersa, com previsões tendencialmente subestimadas para imóveis de preço mais elevado (acima dos 2.500 USD), evidência de que os modelos têm dificuldade em capturar o segmento de luxo. O GBT apresenta uma concentração ligeiramente maior em torno da diagonal, confirmando o seu melhor desempenho.




Gráfico 8 – Distribuição dos Resíduos por Modelos

O histograma dos resíduos (erro = preço real – preço previsto) permite avaliar se os erros se distribuem de forma simétrica em torno de zero o comportamento ideal num modelo sem viés sistemático. Em todos os modelos, a distribuição apresenta-se aproximadamente centrada em zero, o que indica ausência de viés sistemático global. Contudo, a cauda direita é mais longa do que a esquerda, confirmando que o modelo tende a subestimar os imóveis mais caros. O GBT exibe a distribuição mais estreita e simétrica das quatro, o que é coerente com o seu RMSE mais baixo.

6.2 Resultados do Cross-Validation

A otimização por Grid Search testou as seguintes combinações de hiperparâmetros, com os respetivos RMSE médios no CV:

maxDepth	maxIter	RMSE médio CV (USD)
3	10	434,52
3	20	416,56
5	10	402,72
5	20	386,62

A melhor combinação foi $\text{maxDepth}=5$ e $\text{maxIter}=20$, com RMSE médio de 386,62 USD no CV. O modelo final treinado com estes hiperparâmetros obteve RMSE de 384,80 USD e R^2 de 0,5702 no conjunto de teste, confirmando que a otimização gerou um ganho real de desempenho em relação ao GBT base (RMSE 398,01, R^2 0,5402).

6.3 Importância das Features

A análise da importância das features nos modelos Random Forest e GBT revelou resultados consistentes entre ambos. As variáveis mais importantes foram:

- **laundry_options**: a variável com maior importância relativa em ambos os modelos, o que é um resultado surpreendente, mas que pode refletir uma forte correlação entre o tipo de lavanderia disponível e o segmento de mercado do imóvel.
- **long (longitude)**: a segunda variável mais importante, capturando a variação geográfica dos preços. Zonas costeiras e metropolitanas tendem a ter preços significativamente mais elevados.
- **type**: o tipo de imóvel (apartment, house, condo, etc.) tem impacto relevante no preço, com houses e townhouses a apresentarem preços médios mais elevados que apartments.
- **sqfeet**: a área útil do imóvel é a quarta variável mais importante, com uma correlação positiva com o preço. Note-se que, conforme evidenciado pela matriz de correlação (Gráfico 4), as correlações lineares entre as variáveis numéricas e o preço são genericamente próximas de zero, pelo que a importância do sqfeet no modelo se deve à sua contribuição não-linear capturada pelo GBT.

As variáveis **beds** e **state** apresentaram importância muito reduzida em ambos os modelos. No caso de **beds**, a baixa importância pode explicar-se pelo facto de esta variável ser menos granular que **sqfeet** na distinção entre segmentos de mercado. No caso de **state**, a informação geográfica é já capturada de forma mais granular pela longitude.




Gráfico 9 – Comparação da Importância das Features

O gráfico de barras horizontais apresenta, lado a lado, a importância relativa de cada feature no Random Forest (laranja) e no GBT (verde). A consistência entre os dois modelos é notável: **laundry_options** e **long (longitude)** dominam claramente em ambos, seguidos por **type** e **sqfeet**. Este padrão reforça a interpretação de que o segmento de mercado (capturado pelas opções de lavanderia) e a localização geográfica (longitude) são os principais determinantes do preço, à frente das características físicas do imóvel como o número de quartos ou a área.

A baixa importância de state sugere que a longitude já captura a variação geográfica de forma mais granular do que a variável por estado.

7. Análise Crítica

7.1 Desempenho Geral dos Modelos

Os resultados obtidos revelam um desempenho moderado dos modelos, com o melhor R^2 a atingir 0,57. Isto significa que os modelos conseguem explicar cerca de 57% da variância do preço de arrendamento, sendo os restantes 43% influenciados por fatores não presentes no dataset.

Um RMSE de 385 USD e um MAE de 243 USD, num contexto em que a mediana do preço é de 1.037 USD e o intervalo interquartil vai de 806 a 1.395 USD, representam erros absolutos consideráveis. O MAPE de 23% confirma que o modelo erra, em média, cerca de um quarto do valor real. Estes valores são típicos de problemas de predição de preços imobiliários com dados públicos, onde a qualidade do imóvel, o estado de conservação e fatores de proximidade (transportes, escolas, comércio) estão ausentes.

7.2 Comparação entre Modelos

O resultado mais surpreendente foi o fraco desempenho do Random Forest face à Regressão Linear. Sendo um modelo ensemble mais complexo, seria expectável que o Random Forest superasse a Regressão Linear, o que não aconteceu. A explicação mais provável reside nos hiperparâmetros conservadores utilizados: com apenas 20 árvores e profundidade máxima de 5, o Random Forest não teve capacidade suficiente para capturar a complexidade dos dados. Um Random Forest com mais árvores (100 ou 200) e maior profundidade provavelmente obteria melhores resultados.

O GBT superou tanto a Regressão Linear como o Random Forest, confirmando a sua maior capacidade de modelar relações não-lineares através do mecanismo de boosting sequencial. A melhoria do GBT base para o GBT com CV foi consistente em todas as métricas, validando a utilidade da otimização de hiperparâmetros mesmo com um grid relativamente pequeno.

7.3 Limitações do Dataset

O principal fator limitativo do desempenho dos modelos é a própria natureza do dataset. O Craigslist é uma plataforma de anúncios clássicos onde qualquer utilizador pode publicar listagens, o que implica dados de qualidade variável, com erros de inserção e ausência de informação relevante. As principais limitações identificadas foram:

- Ausência de variáveis de qualidade: estado de conservação do imóvel, ano de construção, existência de renovações recentes.
- Ausência de variáveis de localização detalhada: proximidade a transportes públicos, escolas, centros comerciais ou zonas de emprego.
- Dados geográficos pouco granulares: a longitude captura a variação este-oeste dos EUA mas não distingue bairros dentro de uma mesma cidade.
- Elevada proporção de apartments: 84% dos registos são apartments, o que pode enviesar os modelos para este tipo de imóvel.

Feature engineering adicional, como a criação de variáveis de interação (por exemplo, preço por sqfeet ou densidade de listagens por região), ou a integração com dados externos de

qualidade de vida por região, poderia melhorar significativamente o desempenho dos modelos.

7.4 Escolhas Técnicas

A utilização de TRY_CAST para a conversão de tipos na fase de carregamento revelou-se uma decisão acertada, pois evitou falhas de execução causadas por valores mal formatados no dataset, convertendo-os automaticamente para null em vez de lançar exceções. Esta abordagem é mais robusta do que a inferência automática de esquema do Spark.

A escolha da mediana (em vez da média) para imputação de sqfeet foi adequada dado que a distribuição desta variável é assimétrica, com a presença de valores extremos. A média seria inflacionada pelos outliers, enquanto a mediana é mais representativa do valor típico.

A persistência do dataset pré-processado em formato Parquet antes do treino dos modelos foi uma boa prática que permitiu separar claramente as Fases 2 e 3, evitando reprocessamento desnecessário e garantindo que ambas as fases partem do mesmo conjunto de dados.

8. Conclusões

Este projeto permitiu aplicar de forma prática os conceitos de Big Data e machine learning distribuída com Apache Spark, desde o pré-processamento dos dados até ao treino e avaliação de modelos de regressão com Spark MLlib.

O modelo com melhor desempenho foi o GBT com Cross-Validation, obtendo um RMSE de 384,80 USD e um R^2 de 0,5702 no conjunto de teste. Este resultado, embora moderado, é consistente com o esperado para um problema de predição de preços de arrendamento com dados públicos de qualidade variável.

A análise da importância das features revelou que a localização geográfica (longitude) e as características do imóvel (tipo, opções de lavandaria, área) são os principais determinantes do preço, sendo beds e state variáveis de baixo poder preditivo neste dataset específico.

Como trabalho futuro, a incorporação de variáveis de qualidade e de localização mais detalhadas, bem como a exploração de modelos mais avançados como redes neurais ou gradient boosting com hiperparâmetros mais agressivos, poderia melhorar significativamente o poder preditivo dos modelos.

9. Avaliação 360 Graus

Em conformidade com o solicitado no enunciado do projeto, apresenta-se a avaliação individual dos elementos do grupo, numa escala de 0 a 20.

Elemento	Nota (0-20)
Gonçalo Filipe Carvalho Conceição	17
Joana Francisca Brandão Tomé	17

Ambos os elementos contribuíram de forma equivalente para todas as fases do projeto, desde a seleção e exploração do dataset até ao desenvolvimento e documentação do código e do relatório.